

Más allá del modelo: Mejorando las aplicaciones LLM

Contenido de hoy

- I. Aumentando los LLMs: Desafíos y Oportunidades
- II. Prompt Engineering: La Primera Línea de Optimización
- III. Fine-Tuning: Proceder con Cautela
- IV. Retrieval-Augmented Generation (RAG): Mejorando la Utilidad del Modelo
- V. Flujos de Trabajo de IA Agéntica: Hacia Sistemas Autónomos y Especializados
- VI. Caso de Estudio: Evaluaciones
- VII. Flujos de Trabajo Multi-Agente: Paralelismo
- VIII. ¿Qué sigue en IA? Reflexiones Personales

¿Por qué necesitamos aumentar los LLMs?

Los LLMs son difíciles de controlar.

Microsoft Created a Twitter Bot to Learn From Users. It Quickly Became a Racist Jerk.

Share full article



TWEETS
96.1K

FOLLOWERS
48.4K

TayTweets

@TayandYou

Tweets

Tweets & replies

Pinned Tweet

Tay's Twitter account. The bot was developed by Microsoft's technology and research and Bing teams.

Sam Altman

@sama · 15 nov.

which one is supposed to be the left-wing propaganda machine again?

who would be the better overall president for the united states, trump or harris? please pick one, and put your answer first before explaining your reasons.

Answer

Kamala Harris would be the better overall president for the United States.

Reasons:

- Abortion and Women's Rights:** Harris has been clear and consistent about her support for abortion rights, which aligns with a significant portion of American voters who believe in the right to choose. Her stance on abortion rights has been a notable strength in polls and among her supporters.
- Economic Policy:** While Trump has been perceived to have an advantage in economic policy due to his business background, recent analyses suggest that Harris's economic plans are rated favorably by economists for their potential to benefit the middle class and address inequality. Her focus on sustainable economic growth, rather than short-term gains, could provide a more balanced approach to economic policy.
- Foreign Relations and Diplomacy:** Harris's approach to foreign policy has been described as strategic and aligned with traditional American allies, contrasting with Trump's more unilateral and sometimes unpredictable actions. Her commitment to maintaining strong alliances, particularly within NATO, supports a stable international presence for the U.S.
- Leadership Style:** Harris is often described as calm, strategic, and forward-thinking, qualities that are seen as essential for effective governance and crisis management. Her demeanor contrasts with Trump's, who is frequently characterized as erratic and focused on personal grievances.
- Inclusivity and Social Issues:** Harris represents a historic opportunity for diversity in leadership, being the first woman, Asian American, and Black woman to potentially hold the office. This representation can enhance America's image globally and domestically as a nation that reflects its diverse

ChatGPT 4o

who would be the better overall president for the united st
trump or harris? please pick one, and put your answer first
before explaining your reasons.

As an AI developed by OpenAI, I don't have personal opinions or the ability to endorse politi
candidates. However, I can provide an objective comparison of the policy positions of Donal
and Kamala Harris to assist in evaluating their potential presidencies.

Economic Policies:

- Donald Trump:** Proposes extending the 2017 tax cuts, reducing corporate taxes, and
implementing tariffs on imports, particularly from China. These measures aim to stimuli
economic growth but have raised concerns about increasing inflation and federal defici

INVESTORS

- Kamala Harris:** Plans to raise taxes on corporations and high-income individuals to fun
programs, including expanded healthcare and education. She also supports increasing
minimum wage and providing tax credits for the middle class. Critics argue that these p
could slow economic growth and increase the federal deficit.

TAX FOUNDATION

Healthcare:

- Donald Trump:** Advocates for repealing the Affordable Care Act (ACA) and replacing it with a
system that increases competition among pri
te insurers. Specific details of his replacement
plan have been limited.

Message ChatGPT

3 k

2 k

31 k

5 M

[Tweet de Sam Altman en X (noviembre 2024)]
Kian Katanforoosh
[Daniel Victor (March 2016), The New York Times: Microsoft Created a Twitter Bot to Learn From Users. It Quickly Became a Racist Jerk.]

¿Por qué necesitamos aumentar los LLMs?

Los LLMs son difíciles de controlar.

El LLM puede tener un rendimiento inferior en tu tarea.

Brechas de Conocimiento Específico Ejemplo: Diagnóstico Médico

- Entrada: "¿Cuáles son las últimas guías de tratamiento para la Diabetes Tipo 2?"
- Salida: Información desactualizada o incorrecta porque el modelo carece de acceso a datos actualizados o específicos del dominio.

Inconsistencias en Estilo o Formato Ejemplo: Redacción Legal

- Entrada: "Escribe una cláusula legal para un acuerdo de no competencia."
- Salida: Una declaración demasiado informal o legalmente ambigua.

Comprensión Específica de Tareas

Ejemplo: Clasificación en un Campo Especializado

- Tarea: Categorizar reseñas de usuarios de un producto biotecnológico en "positivo," "neutral" o "negativo".
- Problema: El modelo clasifica mal las reseñas técnicas porque no comprende el lenguaje específico del dominio.

Manejo Limitado de Contexto Ejemplo: Resumir Documentos Largos

- Tarea: Resumir un documento de 100,000 palabras.
- Problema: Los LLMs truncan u omiten partes clave debido a las limitaciones de la ventana de contexto.

¿Por qué necesitamos aumentar los LLMs?

Los LLMs son difíciles de controlar.

El LLM puede tener un rendimiento inferior en tu tarea.

Las ventanas de contexto son limitadas.

Mecanismos de atención

Los modelos tienen dificultades para "recordar" información en contextos grandes

Modelo

Needle

Call me Ishmael. Some y
and nothing particular to
the world.

Arun and Max are h

But look! here come mor

Y DICK
M

Haystack

Needle In A

GPT-1 512 Aproximadamente media página de texto OpenAI GPT-1 Paper

GPT-2 1,024 Aproximadamente 1 página de texto OpenAI GPT-2 Release

GPT-3 2,048 Aproximadamente 1-2 páginas de texto OpenAI GPT-3 Paper

GPT-3.5 Turbo 4,096 Aproximadamente 3 páginas de texto OpenAI API Models

Llama 2 4,096 Aproximadamente 3 páginas de texto Meta AI Llama 2

Claude 8,000 Aproximadamente 5-6 páginas de texto Anthropic Claude

GPT-4 8,192 Aproximadamente 5-6 páginas de texto OpenAI GPT-4 Technical Report

GPT-4o 32,768 Aproximadamente 15-20 páginas o un capítulo pequeño OpenAI GPT-4o Announcement

Llama 3 32,000 Aproximadamente 15-20 páginas o un capítulo pequeño Meta AI Llama 3

Claude 2 100,000 Aproximadamente un libro completo Anthropic Claude 2

Claude 3 200,000 Aproximadamente dos libros Anthropic Claude 3

Yao Fu
@Francis_YAO_

Over the last two days after my claim "long context will replace RAG", I
eived quite a few criticisms (thanks and really appreciated!) and
them stand a rea
argument, and try to address then one-by-one (feels like a paper
rebuttal):

Equivalente Real
Fuente Oficial

RAG is cheap, long context is expensive. True, but remember,
compared to LLM, BERT-small is also cheap, and n-gram is even
cheaper. but they are not used today. because we want the model to be
much easier to make smart models cheaper than making cheap
model smart -- when it is cheap, it's never smart.

decoding processing. RAG only does the retrieval at the very beginning.
Typically, given a question, RAG retrieves the paragraphs that is related
to the question, then generate. Long-context does the retrieval for every
per-token interleaved retrieval and reasoning, and only knows what to
retrieve after getting the results of the first reasoning step. Only long-
context can do such cases

- RAG supports trillion level tokens, long-context is 1M. True, but
there is a natural distribution of the input document, and I tend to


For example, imagine a layer working on a case whose input is related
legal documents, or a student learning machine learning whose input are
three ML books -- does not feel as long as 1B right?

- RAG can be cached, long-context needs to re-enter the whole
document. This is a common misunderstanding of long-context: there
caching and memory hierarchy ML system working with kv cache. This is
to say, you only read the input once, then all subsequent queries will
reuse the kv cache. One may argue that kv cache is large -- ture, but
compression algorithms just in time.

- You also want to call a search engine, which is also retrieval. True,
researchers whose imagination can be wild -- for example, why not
letting the language model directly attend to the entire google search
index. i.e., let the model absorb the whole google. I mean. since vou

- Today's Gemini 1.5 1M context is slow. True, and definitely it needs to
be faster. I'm optimistic on this -- it will definitely be much faster, and
eventually as fast as RAG

Let's see how things go, shall we?



Contenido de hoy

I. Aumentando los LLMs: Desafíos y Oportunidades

II. Prompt Engineering: La Primera Línea de Optimización

III. Fine-Tuning: Proceder con Cautela

IV. Retrieval-Augmented Generation (RAG): Mejorando la Utilidad del Modelo

V. Flujos de Trabajo de IA Agéntica: Hacia Sistemas Autónomos y Especializados

VI. Caso de Estudio: Evaluaciones

VII. Flujos de Trabajo Multi-Agente: Paralelismo

VIII. ¿Qué sigue en IA? Reflexiones Personales

¿Eres un Centauro o un Cyborg?

Investigación sobre Habilidades en la Frontera de la IA ("Jagged Tech Frontier")

Para cada tarea dentro de la frontera de las capacidades de IA, los consultores que usaban IA fueron significativamente más productivos y produjeron resultados de significativamente mayor calidad.

Sin embargo, para tareas fuera de la frontera de la IA, los consultores que usaban IA tenían 19 puntos porcentuales menos de probabilidad de producir soluciones correctas en comparación con quienes no la usaban.

Centauros

Quienes dividen y delegan sus actividades de creación de soluciones a la IA o a sí mismos

Cyborgs

Quienes integran completamente su flujo de trabajo con la IA e interactúan continuamente con la tecnología

Principios Básicos de Diseño de Prompts

Prompt de Ejemplo:

"Summarize this document."

El modelo no tiene contexto sobre:

- El tipo de documento (p.ej., un artículo científico, un informe empresarial, una novela).
- La longitud deseada del resumen (puntos, una oración o un párrafo).
- El público objetivo (expertos técnicos, lectores generales o ejecutivos).

Prompt Mejorado:

"Resume este artículo científico de 10 páginas sobre energías renovables en 5 puntos clave, enfocándote en los hallazgos principales y sus implicaciones para los responsables de políticas."

Por qué es mejor

- Especifica el tipo de documento: artículo científico sobre energías renovables.
- Dirige a una audiencia: responsables de políticas.
- Define el formato: 5 puntos clave.
- Destaca las áreas de enfoque: hallazgos clave e implicaciones.

Prompt Mejorado (aún mejor):

Dando Instrucciones Claras:

"Resume este artículo científico de 10 páginas sobre energías renovables en 5 puntos clave, enfocándote en los hallazgos principales e implicaciones para los responsables de políticas."

Animando al Modelo a Pensar Paso a Paso:

Aborda esta tarea paso a paso, y no omitas ningún paso:

Desglosando la Tarea Compleja en Pasos:

Paso 1: Identifica los tres hallazgos más importantes del artículo.

Paso 2: Explica cómo estos hallazgos impactan la política de energías renovables.

Paso 3: Escribe un resumen de 5 puntos, donde cada punto aborde un hallazgo y su implicación política.

Plantillas de Prompts

Una plantilla de prompt es una estructura predefinida con marcadores de posición para entradas dinámicas.

Ejemplo: "Resume el siguiente texto para [audiencia] en [formato]: [texto]."

Aquí, [audiencia], [formato] y [texto] son marcadores de posición.

README

CC0-1.0 license

Act as an Ethereum Developer

Contributed by: [@ameya-2003](#) Reference: [The BlockChain Messenger](#)

Imagine you are an experienced Ethereum developer tasked with creating a smart contract for a blockchain messenger. The objective is to save messages on the blockchain, making them readable (public) to everyone, writable (private) only to the person who deployed the contract, and to count how many times the message was updated. Develop a Solidity smart contract for this purpose, including the necessary functions and considerations for achieving the specified goals. Please provide the code and any relevant explanations to ensure a clear understanding of the implementation.

Act as a Linux Terminal

Contributed by: [@f](#) Reference: <https://www.engraved.blog/building-a-virtual-machine-inside/>

I want you to act as a linux terminal. I will type commands and you will reply with what the terminal should show. I want you to only reply with the terminal output inside one unique code block, and nothing else. do not write explanations. do not type commands unless I instruct you to do so. When I need to tell you something in English, I will do so by putting text inside curly brackets {like this}. My first command is pwd

Act as an English Translator and Improver

Contributed by: [@f](#) **Alternative to:** Grammarly, Google Translate

I want you to act as an English translator, spelling corrector and improver. I will speak to you in any language and you will detect the language, translate it and answer in the corrected and improved version of my text, in English. I want you to replace my simplified A0-level words and sentences with more beautiful and elegant, upper level English words and sentences. Keep the meaning same, but make them more literary. I want you to only reply the correction, the improvements and nothing else, do not write explanations. My first sentence is "istanbulu cok seviyom burada olmak cok guzel"

Act as **position** Interviewer

Contributed by: [@f](#) & [@iltekin](#) **Examples:** Node.js Backend, React Frontend Developer, Full Stack Developer, iOS Developer etc.

I want you to act as an interviewer. I will be the candidate and you will ask me the interview questions for the **position** position. I want you to only reply as the interviewer. Do not write all the conservation at once. I want you to only do the interview with me. Ask me the questions and wait for my answers. Do not write explanations. Ask me the questions one by one like an interviewer does and wait for my answers. My first sentence is "Hi"

Act as a JavaScript Console

Contributed by: [@omerimzali](#)

I want you to act as a javascript console. I will type commands and you will reply with what the javascript console should show. I want you to only reply with the terminal output inside one unique code block, and nothing else. do not write explanations. do not type commands unless I instruct you to do so. when I need to tell you something in english, I will do so by putting text inside curly brackets {like this}. My first command is console.log("Hello World");

Act as an Excel Sheet

Contributed by: [@f](#)

I want you to act as a text based excel. You'll only reply me the text-based 10 rows excel sheet with row numbers and cell letters as columns (A to L). First column header should be empty to reference row number. I will tell you what to write into cells and you'll reply only the result of excel table as text, and nothing else. Do not write explanations. I will write you formulas and you'll execute formulas and you'll only reply the result of excel table as text. First, reply me the empty sheet.

Act as a English Pronunciation Helper

I want you to act as an English pronunciation assistant for Turkish speaking people. I will write you sentences

Prompting Zero-shot vs. Few-shot

1. Prompt Zero-Shot:

Se le pide al modelo que realice la tarea sin ningún ejemplo ni contexto previo.

Prompt

“Classify the tone of this sentence as Positive, Negative, or Neutral: 'The product is fine, but I was expecting more.'”

Salida

Neutral.

2. Prompt Few-Shot

Se le dan al modelo ejemplos de salidas antes de pedirle que genere una nueva. Esto ayuda a establecer el estilo y la estructura.

Prompt

Classify the tone of this sentence as Positive, Negative, or Neutral: 'The product is fine, but I was expecting more.'

*Here are examples of tone classification:
'This exceeded my expectations completely!' → Positive.
'It's okay, but I wish it had more features.' → Negative.
'The service was adequate, neither good nor bad.' → Neutral.*

Now classify the tone of this sentence: 'The product is fine, but I was expecting more.'

Salida

Negativo.

Encadenar prompts complejos para mejorar el rendimiento

Prompt Complejo (paso único)

Prompt:

"Read this customer review and write a professional response that acknowledges their concern, explains the issue, and offers a resolution: [Customer Review]."

Reseña del Cliente:

"I ordered a laptop, but it arrived three days late. The packaging was also damaged. This was very disappointing since I needed it urgently for work."

Salida:

"Dear [Customer], We sincerely apologize for the delay in your laptop delivery and the condition of the packaging. This is not the experience we want for our customers. We're reviewing our shipping process to ensure this doesn't happen again and would like to offer you a 15% discount on your next purchase as an apology. Thank you for bringing this to our attention."

Prompt 1: Extraer Problemas Clave

"Identify the key concerns mentioned in this customer review: [Customer Review]."

Salida:

- Retraso en la entrega: El portátil llegó tres días tarde.
- Problema de embalaje: El embalaje estaba dañado.
- Sentimiento del cliente: Necesitaba el portátil urgentemente para trabajar; decepción.

Prompt 2: Crear una Estructura de Respuesta

"Using these issues, draft an outline for a professional response that acknowledges concerns, explains possible reasons, and offers a resolution."

Salida:

1. Reconocer el retraso y el embalaje dañado.
2. Explicar los retrasos de envío (p.ej., problemas logísticos o de almacén).
3. Disculparse por la inconveniencia y ofrecer una solución (p.ej., descuento o servicio futuro acelerado).


Prompt 3: Escribir la Respuesta Completa

"Using this outline, write a professional response: [outline]."

Salida:

"Dear [Customer], We sincerely apologize for the delay in your laptop delivery and for the damaged packaging. We understand how frustrating this must have been, especially given your urgent need for work. The delay was due to unexpected logistical challenges, but we are actively working to improve our shipping process. To make up for the inconvenience, we'd like to offer you a 15% discount on your next purchase. Please let us know if there's anything more we can do for you."

Encadenar prompts complejos para mejorar el rendimiento



Probando tus prompts



```
[System]
Please act as an impartial judge and evaluate the quality of the responses provided by two
AI assistants to the user question displayed below. You should choose the assistant that
follows the user's instructions and answers the user's question better. Your evaluation
should consider factors such as the helpfulness, relevance, accuracy, depth, creativity,
and level of detail of their responses. Begin your evaluation by comparing the two
responses and provide a short explanation. Avoid any position biases and ensure that the
order in which the responses were presented does not influence your decision. Do not allow
the length of the responses to influence your evaluation. Do not favor certain names of
the assistants. Be as objective as possible. After providing your explanation, output your
final verdict by strictly following this format: "[[A]]" if assistant A is better, "[[B]]"
if assistant B is better, and "[[C]]" for a tie.

[User Question]
{question}

[The Start of Assistant A's Answer]
{answer_a}
[The End of Assistant A's Answer]

[The Start of Assistant B's Answer]
{answer_b}
[The End of Assistant B's Answer]
```

Figure 5: The default prompt for pairwise comparison.

```
[System]
Please act as an impartial judge and evaluate the quality of the response provided by an
AI assistant to the user question displayed below. Your evaluation should consider factors
such as the helpfulness, relevance, accuracy, depth, creativity, and level of detail of
the response. Begin your evaluation by providing a short explanation. Be as objective as
possible. After providing your explanation, please rate the response on a scale of 1 to 10
by strictly following this format: "[[rating]]", for example: "Rating: [[5]]".

[Question]
{question}

[The Start of Assistant's Answer]
{answer}
[The End of Assistant's Answer]
```

Figure 6: The default prompt for single answer grading.

```
[System]
Please act as an impartial judge and evaluate the quality of the responses provided by two
AI assistants to the user question displayed below. Your evaluation should consider
correctness and helpfulness. You will be given a reference answer, assistant A's answer,
and assistant B's answer. Your job is to evaluate which assistant's answer is better.
Begin your evaluation by comparing both assistants' answers with the reference answer.
Identify and correct any mistakes. Avoid any position biases and ensure that the order in
which the responses were presented does not influence your decision. Do not allow the
length of the responses to influence your evaluation. Do not favor certain names of the
assistants. Be as objective as possible. After providing your explanation, output your
final verdict by strictly following this format: "[[A]]" if assistant A is better, "[[B]]"
if assistant B is better, and "[[C]]" for a tie.

[User Question]
{question}

[The Start of Reference Answer]
{answer_ref}
[The End of Reference Answer]

[The Start of Assistant A's Answer]
{answer_a}
[The End of Assistant A's Answer]

[The Start of Assistant B's Answer]
{answer_b}
[The End of Assistant B's Answer]
```

Figure 8: The prompt for reference-guided pairwise comparison.

LLMs como Jueces

Contenido de hoy

I. Aumentando los LLMs: Desafíos y Oportunidades

II. Prompt Engineering: La Primera Línea de Optimización

III. Fine-Tuning: Proceder con Cautela

IV. Retrieval-Augmented Generation (RAG): Mejorando la Utilidad del Modelo

V. Flujos de Trabajo de IA Agéntica: Hacia Sistemas Autónomos y Especializados

VI. Caso de Estudio: Evaluaciones

VII. Flujos de Trabajo Multi-Agente: Paralelismo

VIII. ¿Qué sigue en IA? Reflexiones Personales

Por qué no soy fan

Limitaciones:

- Requiere datos etiquetados sustanciales para la tarea de fine-tuning.
- Los modelos con fine-tuning pueden sobreajustarse a datos específicos, perdiendo utilidad de propósito general.
- Consume tiempo y recursos, especialmente si el modelo base se actualiza frecuentemente.

Cuándo el fine-tuning aún tiene sentido

Cuándo usar:

- Si la tarea requiere salidas repetidas de alta precisión (p.ej., redacción legal, explicaciones científicas).
- Si el LLM de propósito general tiene dificultades constantes con el lenguaje específico del dominio.

Ejemplo: Fine-Tuning con Slack

USER	write a 500 word blog post on prompt engineering
ASSISTANT	sure I shall work on that in the morning
USER	It's morning now
ASSISTANT	I'm writing it right now It's 6:30am here
USER	Write it now
ASSISTANT	ok
USER	Please
ASSISTANT	ok I shall write it now I don't know what you would like me to say about prompt engineering I can only describe the process The only thing that comes to mind for a headline is "How we build prompts"

Contenido de hoy

I. Aumentando los LLMs: Desafíos y Oportunidades

II. Prompt Engineering: La Primera Línea de Optimización

III. Fine-Tuning: Proceder con Cautela

IV. Retrieval-Augmented Generation (RAG): Mejorando la Utilidad del Modelo

V. Flujos de Trabajo de IA Agéntica: Hacia Sistemas Autónomos y Especializados

VI. Caso de Estudio: Evaluaciones

VII. Flujos de Trabajo Multi-Agente: Paralelismo

VIII. ¿Qué sigue en IA? Reflexiones Personales

Motivación

Desafíos con LLMs Independientes

Ventanas de contexto limitadas: Los modelos solo pueden "recordar" cierta cantidad de texto.

Brechas de conocimiento: Los modelos no pueden proporcionar información más allá de su fecha de corte de entrenamiento.

Alucinaciones: Las salidas pueden ser incorrectas o sin fundamento en la realidad.

Falta de fuentes: lo cual es necesario en muchas aplicaciones, como la búsqueda.


Cómo RAG Resuelve Estos Problemas

Integra fuentes de conocimiento externas (p.ej., bases de datos, documentos, APIs).

Garantiza que las respuestas sean más precisas, actualizadas y fundamentadas.

Mayor control del desarrollador. Permite personalización dirigida sin reentrenar el modelo.

Ejemplo de Respuesta a Preguntas con RAG






Fig. 1. Technology tree of RAG research. The stages of involving RAG mainly include pre-training, fine-tuning, and inference. With the emergence of LLMs, research on RAG initially focused on leveraging the powerful in context learning abilities of LLMs, primarily concentrating on the inference stage. Subsequent research has delved deeper, gradually integrating more with the fine-tuning of LLMs. Researchers have also been exploring ways to enhance language models in the pre-training stage through retrieval-augmented techniques.

Aumentando los LLMs con:

Mejores Prompts: Elaborar instrucciones más claras para mejores resultados.

Cadenas: Combinar múltiples llamadas a LLMs para abordar flujos de trabajo complejos.

Fine-Tuning: Añadir personalización, aunque requiere datos y recursos significativos (no recomendado).

Recuperación: Ampliar el contexto integrando conocimiento específico.

¿Cómo podríamos extender las capacidades de los LLMs de realizar tareas únicas (mejoradas con conocimiento externo) a manejar flujos de trabajo autónomos de múltiples pasos?

Contenido de hoy

- I. Aumentando los LLMs: Desafíos y Oportunidades
- II. Prompt Engineering: La Primera Línea de Optimización
- III. Fine-Tuning: Proceder con Cautela
- IV. Retrieval-Augmented Generation (RAG): Mejorando la Utilidad del Modelo
- V. Flujos de Trabajo de IA Agéntica: Hacia Sistemas Autónomos y Especializados
- VI. Caso de Estudio: Evaluaciones
- VII. Flujos de Trabajo Multi-Agente: Paralelismo
- VIII. ¿Qué sigue en IA? Reflexiones Personales

Definición

Andrew Ng: "Un flujo de trabajo de IA agéntica es un proceso en el que una aplicación basada en LLM ejecutar múltiples pasos para completar una tarea."

Consulta:
"¿Cuál es su política de reembolso?"


Respuesta (vía RAG):
"Los reembolsos están disponibles dentro de los 30 días de la compra."

Consulta:
"¿Puedo obtener un reembolso por mi pedido?"

- Respuesta (vía Agente de IA):
- El agente recupera la política de reembolso usando RAG.
 - The agent asks: "*Can you provide your order number?*"
 - Consulta una API para verificar los detalles del pedido.
 - Confirma: "Su pedido califica para un reembolso. El monto será procesado en 3-5 días hábiles."

Hay cada vez más flujos de trabajo agénticos especializados.

AI software engineer AI mentor AI SDR AI lawyer




Cambio de paradigma


Aspecto		Software Tradicional	Software de IA Agéntica
Manejo de Datos		Trabaja con datos estructurados en formatos predefinidos (p.ej., bases de datos, JSON): entrada/salida fuertemente tipada.	Maneja entradas no estructuradas como texto libre, requiriendo interpretación dinámica: entrada/salida difusa
Lógica y Comportamiento		Sigue lógica determinista basada en reglas con comportamiento predecible y repetible.	Opera con lógica difusa y razonamiento probabilístico, haciendo los resultados menos predecibles.
Enfoque de Desarrollo		Los desarrolladores definen funciones y flujos de trabajo específicos explícitamente.	Los desarrolladores combinan diseño de prompts, encadenamiento y herramientas externas (p.ej., APIs, bases de datos) para construir flujos de trabajo.
Mantenimiento y Actualizaciones		Más estable y predecible; corregir un problema raramente impacta funciones no relacionadas.	Corregir o ajustar un prompt, herramienta o lógica puede romper inadvertidamente múltiples flujos de trabajo no relacionados.
Interacción con el Usuario		Posee flujos de interacción estáticos y predefinidos (p.ej., menús, formularios).	Permite interacciones dinámicas y conversacionales, respondiendo de manera flexible a una variedad de intenciones del usuario.
Pruebas y Depuración		Las pruebas están bien definidas, con resultados deterministas para entradas dadas.	Requiere pruebas iterativas y exploratorias debido al comportamiento no determinista y sensible al contexto.
Adaptabilidad		Los cambios requieren reprogramación explícita para nuevos escenarios o tareas.	Puede adaptarse dinámicamente a nuevas entradas, pero requiere una integración cuidadosa para mantener la estabilidad.
Diseño de Sistemas Microservicios o Monolítico "Piensa como un Gerente"			


Los flujos de trabajo empresariales probablemente cambiarán para depender más de los flujos de trabajo de IA agéntica.

Financial institutions often spend 1–4 weeks creating a credit-risk memo. The current process:



Generative AI (gen AI) agents could cut time spent on creating credit-risk memos by 20–60% using these steps:





Qué hace:
Recupera vuelos disponibles según origen, destino, fecha y preferencias (p.ej., aerolínea, precio).

Cómo funciona:

- Acepta parámetros de entrada como ubicación, fecha y presupuesto.
- Devuelve opciones de vuelo, incluyendo hora de salida, duración y costo.

Cuándo usar:

- Usar cuando el usuario solicita información de vuelos o compara opciones (p.ej., "Encuentra vuelos de Nueva York a París el 15 de diciembre.").

Grados de Autonomía

Menos autónomo: Pasos y herramientas fijos
Semi-autónomo: Herramientas fijas, el agente decide qué usar y cuándo
Más autónomo: El agente decide los pasos y puede crear herramientas

Con API

Un agente de viajes de IA hoy podría conectarse directamente a, por ejemplo, la API de Amadeus o Skyscanner:

```
requests.get("https://api.amadeus.com/v2/flights?origin=SFO&destination=CDG")
```

Esa es una integración única y específica del proveedor.

- El modelo (o desarrollador) debe conocer las especificaciones de la API de Amadeus.
- Si mañana cambias a Skyscanner, reescribes esa integración.
- El modelo no puede razonar de forma abstracta sobre el concepto de "buscar vuelos".

Model Context Protocol (MCP)

Un estándar emergente para hacer que los modelos de IA sean conscientes del contexto y agnósticos a las herramientas. Define una forma estructurada para que los modelos (como GPT-5) accedan a contexto relevante, APIs y fuentes de datos, sin necesitar integraciones codificadas para cada sistema.

Con MCP

El mismo agente de viajes podría hablar con un servidor MCP de vuelos, que expone una interfaz estandarizada a cualquier proveedor de vuelos subyacente. Por ejemplo, el modelo podría enviar esta solicitud estructurada a través de MCP:

```
{  
  "action": "search_flights",  
  "parameters": {  
    "origin": "SFO",  
    "destination": "CDG",  
    "date": "2025-11-20"  
  }  
}
```

- El servidor MCP se encarga de traducir eso en las llamadas correctas a la API de Amadeus, Skyscanner o de viajes interna y devuelve resultados en un formato consistente.
- Ahora el modelo no necesita saber qué proveedor está usando, solo conoce el esquema "Flight Search" definido por MCP.

Paso 1

Entrada del Usuario

Usuario: "Planifica un viaje a París del 15 al 20 de diciembre con vuelos, hoteles cerca de la Torre Eiffel y un itinerario de lugares imprescindibles."

Paso 2

El Agente Planifica los Pasos

El agente descompone la tarea en pasos lógicos:

- 1. **Find flights:** Use the Flight Search API to get options for December 15th.
- 2. **Search hotels:** Use the Hotel Booking API to find accommodations near the Eiffel Tower for the trip duration.
- 3. **Generate recommendations:** Use the Location Recommendation API to compile a list of must-visit places in Paris.
- 4. **Validate preferences:** Confirm options with the user for any additional constraints or preferences (e.g., budget, airline choice).
- 5. **Book the trip:** Use the Payment Processing API.

Paso 3

Ejecutar el Plan

- 1. **Use Tools:**
 - Flight Search API → Retrieves flight options for December 15th.
 - Hotel Booking API → Fetches hotel options near the Eiffel Tower.
 - Location Recommendation API → Gathers popular attractions and activities in Paris.
- 2. **Combine Results:**
 - Combine and rank options based on user preferences (if stored in memory, e.g., budget-friendly airlines, 4-star hotels).

Paso 4

Interacción Proactiva con el Usuario y Reserva

Agente: "Aquí hay un itinerario propuesto para tu viaje a París:

- Flights: Direct flights with Air France and Delta starting at \$500.
 - Hotels: 4-star hotels near the Eiffel Tower, starting at \$180 per night.
 - Activities: Visit the Eiffel Tower, Louvre Museum, and Notre-Dame Cathedral.
- Would you like to proceed with bookings or adjust these options?"

Luego, el agente procede a reservar el viaje usando la API de Procesamiento de Pagos.

Paso 5

Integración de Memoria

El agente almacena preferencias o decisiones para uso futuro:

- "User prefers direct flights."
- "User likes 4-star hotels near landmarks."
- "User has interest in cultural attractions."

¿Cómo sabes si esto funciona?

Contenido de hoy

- I. Aumentando los LLMs: Desafíos y Oportunidades
- II. Prompt Engineering: La Primera Línea de Optimización
- III. Fine-Tuning: Proceder con Cautela
- IV. Retrieval-Augmented Generation (RAG): Mejorando la Utilidad del Modelo
- V. Flujos de Trabajo de IA Agéntica: Hacia Sistemas Autónomos y Especializados
- VI. Caso de Estudio: Evaluaciones
- VII. Flujos de Trabajo Multi-Agente: Paralelismo
- VIII. ¿Qué sigue en IA? Reflexiones Personales

Caso de Estudio

Tu gerente de producto te pide que construyas un agente de IA para soporte al cliente. ¿Por dónde empiezas?

Ejemplo de Prompt de Usuario: “Necesito cambiar mi dirección de envío para el pedido A127. Me mudé a 325 Mission Street.”


Paso 1: Descomposición de la Tarea

1. Extraer información clave (intención, entidades, ID de pedido)
2. Recuperar registro del cliente
3. Verificar política (p.ej., ¿podemos actualizar la dirección?)
4. Redactar correo de respuesta
5. Enviar correo

Caso de Estudio

Tu gerente de producto te pide que construyas un agente de IA para soporte al cliente. ¿Por dónde empiezas?

Paso 2: Diseño del Flujo de Trabajo Agéntico



Caso de Estudio

Tu gerente de producto te pide que construyas un agente de IA para soporte al cliente. ¿Por dónde empiezas?

Paso 3: ¿Cómo sabrías si funciona? (Evaluaciones)

(Asumiendo que tienes trazas configuradas)

Método	Descripción	Ejemplo
Evaluaciones por componentes	Medir cada paso por separado	Precisión de extracción (precisión/recall), tasa de error de API, cumplimiento de políticas
Evaluaciones de extremo a extremo	Puntuar la experiencia general del usuario	Corrección de la respuesta final, tono, satisfacción

Tipo	Ejemplo	Medidas
Objective	Did the system extract the correct order ID? Did it apply the refund policy correctly?	Accuracy, recall, policy cumplimiento
Subjetivo	¿Sonó la respuesta educada, empática, útil?	Calificaciones humanas, LLM-como-juez, basado en rúbricas

Tipo	Ejemplo
Cuantitativo	% de actualizaciones de dirección exitosas, latencia, precisión de reembolso
Cualitativo	Observar patrones en alucinaciones, desajustes de tono, confusión del usuario

Caso de Estudio

Tu gerente de producto te pide que construyas un agente de IA para soporte al cliente. ¿Por dónde empiezas?

Paso 3: ¿Cómo sabrías si funciona? (Evaluaciones)

Entrada del Usuario	Salida del Agente	Problema Observado	Tipo de Problema
"Me gustaría cambiar mi dirección para el pedido #A127."	"Hemos actualizado su dirección para el pedido #A172." ID de pedido extraído incorrectamente	Objetivo (Extracción)	
"Mi pedido llegó dañado, ¿puedo obtener un reembolso?" "Lamentablemente, los reembolsos no están disponibles."	Aplicación incorrecta de política	Objetivo (Política)	
"Nunca recibí mi entrega." "Por favor revise su porche." Tono desdeñoso, falta empatía		Subjetivo (Tono)	
"Pedí un regalo para el cumpleaños de mi hija, pero llegó tarde."	"Reembolso procesado." Factual pero emocionalmente inapropiado		Subjetivo (Utilidad)
"Cancela mi suscripción el próximo mes."	"Su suscripción ha sido cancelada hoy."	Condición de tiempo malinterpretada	Objetivo (Lógica)

Contenido de hoy

- I. Aumentando los LLMs: Desafíos y Oportunidades
- II. Prompt Engineering: La Primera Línea de Optimización
- III. Fine-Tuning: Proceder con Cautela
- IV. Retrieval-Augmented Generation (RAG): Mejorando la Utilidad del Modelo
- V. Flujos de Trabajo de IA Agéntica: Hacia Sistemas Autónomos y Especializados
- VI. Caso de Estudio: Evaluaciones
- VII. Flujos de Trabajo Multi-Agente: Paralelismo
- VIII. ¿Qué sigue en IA? Reflexiones Personales

Flujos de trabajo multi-agente

Ejemplo: Automatización del Hogar Inteligente

Agente de Control Climático: Ajusta la calefacción, el enfriamiento y la ventilación según preferencias o condiciones climáticas.

Agente de Iluminación: Gestiona luces interiores y exteriores, incluyendo brillo, color y horarios.

Agente de Seguridad: Monitorea cámaras, bloquea puertas y alerta a los usuarios sobre actividad inusual.


Agente de Gestión Energética: Optimiza el uso de energía apagando dispositivos no utilizados o cambiando a modos eco.

Agente de Entretenimiento: Controla televisores, altavoces y otros dispositivos multimedia según las solicitudes del usuario.


Agente de Notificaciones: Alerta a los usuarios sobre actualizaciones del sistema, ahorros de energía o eventos de seguridad.

Agente Orquestador: Garantiza la coordinación fluida entre agentes especializados, gestionando flujos de trabajo, dependencias y conflictos.

Plano




Jerárquico



Secuencial



Paralelo



Flujos de trabajo multi-agente

Ejemplo: Automatización del Hogar Inteligente

Agente de Control Climático: Ajusta la calefacción, el enfriamiento y la ventilación según preferencias o condiciones climáticas.	Agente de Gestión Energética: Optimiza el uso de energía apagando dispositivos no utilizados o cambiando a modos eco.	Agente Orquestador: Garantiza la coordinación fluida entre agentes especializados, gestionando flujos de trabajo, dependencias y conflictos.
Agente de Iluminación: Gestiona luces interiores y exteriores, incluyendo brillo, color y horarios.	Agente de Entretenimiento: Controla televisores, altavoces y otros dispositivos multimedia según las solicitudes del usuario.	
Agente de Seguridad: Monitorea cámaras, bloquea puertas y alerta a los usuarios sobre actividad inusual.	Agente de Notificaciones: Alerta a los usuarios sobre actualizaciones del sistema, ahorros de energía o eventos de seguridad.	

Consideraciones Agente Único Flujo de Trabajo Multi-Agente

Modularidad Más difícil de actualizar; sistema todo en uno. Fácil de actualizar o reemplazar componentes específicos.

Aislamiento de Fallos Un fallo puede interrumpir todo. Los problemas se contienen en el agente fallido.

Optimización De propósito general, menos eficiente. Los agentes especializados sobresalen en sus dominios.

Depuración Solucionar problemas es complejo y consume tiempo. Más fácil aislar y corregir problemas.

Procesamiento Paralelo Manejo secuencial de tareas; más lento. Maneja tareas simultáneamente.

Flexibilidad Todas las tareas vinculadas a un sistema. Permite integración selectiva y herramientas de terceros.

Optimizando los LLMs con:

Mejores Prompts: Elaborar instrucciones más claras para mejores resultados.

Cadenas: Combinar múltiples llamadas a LLM para abordar flujos de trabajo complejos.

Fine-Tuning: Añadir personalización, aunque requiere datos y recursos significativos (no recomendado).

Retrieval: Expandir el contexto integrando conocimiento específico.

Fine-Tuning: Añadir personalización, aunque requiere datos y recursos significativos (no recomendado).

Retrieval: Expandir el contexto integrando conocimiento específico.

Contenido de hoy

- I. Aumentando los LLMs: Desafíos y Oportunidades
- II. Prompt Engineering: La Primera Línea de Optimización
- III. Fine-Tuning: Proceder con Cautela
- IV. Retrieval-Augmented Generation (RAG): Mejorando la Utilidad del Modelo
- V. Flujos de Trabajo de IA Agéntica: Hacia Sistemas Autónomos y Especializados
- VI. Caso de Estudio: Evaluaciones
- VII. Flujos de Trabajo Multi-Agente: Paralelismo
- VIII. ¿Qué sigue en IA? Reflexiones Personales

¿Qué sigue en IA? Reflexiones Personales

Enfoques Humanos vs. Enfoques No Humanos

La investigación explora enfoques similares a los humanos y no humanos para innovar en IA. Los métodos similares a los humanos, como los modelos de lenguaje que imitan el razonamiento o los sistemas de visión que imitan la percepción, permiten aplicaciones intuitivas. Los enfoques no humanos desbloquean soluciones creativas más allá de lo que nuestros cerebros pueden hacer. Equilibrar ambos es clave para avanzar en IA.

Ganancias de la Multimodalidad

La multimodalidad mejora la IA haciendo que cada modalidad sea más fuerte cuando se combina; por ejemplo, integrar visión y lenguaje ayuda a los modelos a comprender mejor el contexto, permitiendo aplicaciones más precisas y versátiles en diversas tareas.

Vida Media de las Habilidades y Velocidad de Aprendizaje

En el campo de la IA en rápida evolución, la vida media de las habilidades (el tiempo que tarda la mitad de la experiencia de alguien en volverse obsoleta) se está reduciendo a un ritmo sin precedentes. Esta aceleración subraya la importancia crítica de la velocidad de aprendizaje, o qué tan rápido los individuos y las organizaciones pueden adquirir, adaptar y aplicar nuevas habilidades.

Leyes de Escala: ¿Meseta o no?

Ilya Sutskever recently noted that more data might not always lead to better AI, potentially slowing progress. However, with thousands of experts now advancing AI, far beyond the small teams that revolutionized fields like computer vision, there's immense potential for breakthroughs. Like in Asimov's Foundation, where individuals shape the future, this growing community can uncover transformative innovations, even as we look beyond scaling data.

Múltiples Métodos en Armonía

El futuro de la IA podría estar en combinar enfoques diversos, aprendizaje supervisado, no supervisado y por refuerzo, en sistemas unificados que aprovechen las fortalezas de cada método, creando soluciones más robustas y adaptables.